

# Pravděpodobnost a Statistika 1

Poznámky z přednášek

Letní semestr 2020/2021

Viktor Soukup, Lukáš Salak

# Obsah

# 1 První přednáška

Modely náhody  $\rightarrow$  Pravděpodobnost  $\rightarrow$  Pozorovaná data  $\rightarrow$  Modely náhody

Model náhody např. kostka  $1, \dots, 6$ ,

Pozorovaná data :  $1, 5, 4, 3, 3$

otázka na pravděpodobnost: jaká je pravděpodobnost... hodně pozorovaných dat  $\rightarrow$  statistika na model náhody.

**Příklad** (Schwartz-Zippel algoritmus): Máme dány dva polynomy  $f(x), g(x)$  stupně  $d$ . Chceme zjistit, zda jsou stejné, a to co nejrychleji.

Problém:  $g(x)$  je součin několik polynomů stupně  $\leq \frac{d}{4}$ , dostáváme víc než lineární čas.

**Řešení:** Algoritmus: zvolíme náhodně  $x \in \{1, 2, \dots, 100d\}$ , ověříme, zda  $f(x_1) = g(x_1)$ . Když  $f \neq g$ , tak  $x_1$  je kořen polynomu  $f - g$ . ... takových  $x_1$  je  $\leq d$ .

$$P(f(x_1) = g(x_1) : f \neq g) \leq \frac{1}{100}$$

Pokud jsme spokojeni s 1%, končíme, když ne, volíme  $x_2, x_3, \dots \in \{1, 2, \dots, 100d\}$ , pak

$$P(\text{Pro } x_1, x_2, x_3 \dots f(x_i) = g(x_i) : f \neq g) \leq \left(\frac{1}{3}\right)^3 = 10^{-6}$$

... aproximační algoritmy

Některé jevy neumíme/nechceme popsat kauzálně

1. hod kostkou
2. tři hody kostkou, nekonečně mnoho hodů kostkou
3. hod šípkou na terč
4. počet emailů za den
5. dobu běhu programu (v reálném počítači)...

Důvody:

- fyzikální vlastnost přírody
- komplikovaný proces (počasí, medicína, molekuly plynu...)
- neznáme vlivy (působení dalších lidí, programů...)
- randomizované algoritmy (test prvočíselnosti, quicksort)
- náhodné grafy (Ramseyovy čísla)

Pro popis pomocí teorie pravděpodobnosti napřed vybereme množinu elementárních jevů  $\Omega$  (sample space)

$$\Omega = \{1, 2, \dots, 6\} = [6] \implies \text{hod kostkou}$$

$$\Omega = [6]^3 \implies \text{hod třemi kostkami}$$

**Definice** (Prostor jevů):  $\mathcal{F} \subseteq \mathcal{P}(\Omega)$

$\mathbb{F} \subseteq \mathbb{P}(\Omega)$  je prostor jevů (též  $\sigma$ -algebra), pokud

1.  $\emptyset \in \mathcal{F}$  a  $\Omega \in \mathcal{F}$
2.  $A \in \mathcal{F} \implies \Omega \setminus A \in \mathcal{F}$
3.  $A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$

Často  $\mathcal{F} = \mathcal{P}(\Omega)$ , to je možné vždy, když je  $\Omega$  spočetná, např. pro  $\Omega = \mathbb{R}$  to již nejde.

**Definice** (Pravděpodobnost):  $P : \mathcal{F} \rightarrow [0, 1]$  se nazývá pravděpodobnost (probability), pokud:

1.  $P(\emptyset) = 0, P(\Omega) = 1$ , a
2.  $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ , pro libovolnou posloupnost po dvou *disjunktních* jevů **TODOOT**

Šance (odds) jevu  $A$  je  $O(A) = \frac{P(A)}{P(A^c)}$ . Např. šance na výhru je 1 ku 2 znamená, že pravděpodobnost výhry je  $\frac{1}{3}$ ; šance, že na kostce padne šestka je 1 ku 5.

**Konvence:**

- „ $A$  je jistý jev“ znamená  $P(A) = 1$ . Také se říká, že  $A$  nastává skoro jistě (almost surely), zkráceně s.j. (a.s.).
- „ $A$  je nemožný jev“ znamená  $P(A) = 0$ .

$$P(A) = 0 \Rightarrow^? A = \emptyset$$

$\leftarrow$  axiom

$\rightarrow$  platí často, ne vždy

- Např.  $A = \text{střed kruhu (házení šipek na terč)} \implies P(A) = 0$   $B$  spočetná (konečná, velká jako  $\mathbb{N}$ ) množina:

$$P(B) = 0 + 0 + 0 + \dots = 0$$

$B_i$  je  $i$ -tý bod,  $B = \bigcup B_i$

**Věta** (Vlastnosti pravděpodobnostního prostoru): V pravděpodobnostním prostoru  $(\Omega, \mathcal{F}, P)$  platí pro  $A, B \in \mathcal{F}$ :

1.  $P(A) + P(A^c) = 1$
2.  $A \subseteq B \implies P(A) \leq P(B)$
3.  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
4.  $P(A_1 \cup A_2 \cup \dots) \leq \sum_i P(A_i)$  (subaditiva, Booleova nerovnost) (nevyžadujeme disjunktnost, pak by platila rovnost)

**Důkaz:**

1.  $\Omega = A \cup A^c$ ;  $A, A^c$  disj.,  
 $1 = P(\Omega) = P(A) + P(A^c)$
2.  $P(B) = P(A) + P(B \setminus A) \geq P(A)$
3. cvičení **TODOOT**

4. trik zdisjunktnění: z  $A_1, A_2 \dots$  uděláme disjunktní množiny

$$B_1 = A_1, B_2 = A_2 \setminus A_1, B_3 = A_3 \setminus A_1 \cup A_2 \dots$$

$$B_i \subseteq A_i \implies P(B_i) \leq P(A_i)$$

$$B_i \cap B_j = \emptyset : j < i \dots B_i \cap B_j \subseteq B_i \cap A_j = \emptyset$$

$$\bigcup_{i=1}^{\infty} B_i = \bigcup_{i=1}^{\infty} A_i$$

$$\subseteq \text{ok}$$

opačná inkluze **TODOOT**

$$P\left(\bigcup A_i\right) = P\left(\bigcup B_i\right) = \sum P(B_i) \leq \sum P(A_i).$$

□

**Příklad** (Pravděpodobnostní prostory):

1. Konečný s uniformní pravděpodobností

$\Omega$  je libovolná konečná množina,  $\mathcal{F} = \mathcal{P}(\Omega)$ ,

$$P(A) = \frac{|A|}{|\Omega|}.$$

2. Diskrétní

$\Omega = \{\omega_1, \omega_2 \dots\}$  je libovolná spočetná množina. Jsou dány  $p_1, p_2 \dots \in [0, 1]$  se součtem 1.

$P(A) = \sum_{i: \omega_i \in A} p_i$  (cinknutá loterie, nějaké možnosti mají jiné procenta)

3. Spojitý

$\Omega \subseteq \mathbb{R}^d$  pro vhodné  $d$  ( $\Omega$  např. uzavřená nebo otevřená)

$\mathcal{F}$  vhodná (obsahuje např. všechny otevřené množiny)

$f: \Omega \rightarrow [0, 1]$  je funkce taková, že  $\int_{\Omega} f(x) dx = 1$ .

$$P(A) = \int_A f(x) dx$$

Speciální případ:  $f(x) = 1/V_d(\Omega)$

$P(A) = \frac{V_d(A)}{V_d(\Omega)}$ , kde  $V_d(A) = \int_A 1$  je  $d$ -rozměrný objem  $A$ .

4. Bernoulliho krychle - nekonečné opakování

$\Omega = S^{\mathbb{N}}$ , kde  $S$  je diskrétní s pravděpodobností  $Q$ ,

$\mathcal{F}$  vhodná (obsahuje např. všechny množiny tvaru

$$A = A_1 \times \dots \times A_k \times S \times S \times \dots)$$

$$P(A) = Q(A_1) \dots Q(A_k)$$

**Příklad** (Nepříklady):

1. Náhodné přirozené číslo: můžeme si vybrat mnoha způsoby, Ale všechna přirozená čísla nemají stejnou pravděpodobnost.

není možné, aby měly všechny stejnou nenulovou pravděpodobnost, protože pokud  $P(0) = P(1) = P(2) \dots = P$  tak  $P(\mathbb{N}) = p + p + p \dots = \infty$ .

2. Náhodné reálné číslo

3. Betranův paradox

**Definice** (Podmíněná pravděpodobnost): Pokud  $A, B \in \mathcal{F}$  a  $P(B) > 0$ , pak definujeme podmíněnou pravděpodobnost A při B (probability of A given B) jako

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

$Q(A) := P(A|B)$ . Pak  $(\Omega, \mathcal{F}, Q)$  je pravděpodobnostní prostor.

**Definice** (Zřetězené podmínování):  $P(A \cap B) = P(B)P(A|B)$

**Věta:** Pokud  $A_1, \dots, A_n \in \mathcal{F}$  a  $P(A_1 \cap \dots \cap A_n) > 0$ , tak

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1) \dots \text{TODOOT}$$

## 2 Druhá přednáška

### 2.1 Opakování

1. definice pravděpodobnostního prostoru  $(\Omega, \mathcal{F}, P)$ : dva axiomy,
2. **naivní** pravděpodobnostní prostor:  $\Omega$  konečná,  $\mathcal{F} = \mathcal{P}(\Omega)$   
 $P(A) := |A|/|\Omega|$
3. **diskrétní** pravděpodobnostní prostor:  $\Omega = \omega_1, \omega_2, \dots$ ,  
 $\mathcal{F} = \mathcal{P}(\Omega), \sum_i p_i = 1$   
 $P(A) := \sum_{i: \omega_i \in A} p_i$
4. **geometrický** pravděpodobnostní prostor:  
 $\omega \subseteq \mathbb{R}^d$  s konečným objemem,  
 $P(A) := V_d(A)/V_d(\Omega)$
5. pravděpodobnostní prostor **spojitý s hustotou**:  
 $\Omega \subseteq \mathbb{R}^d$  s funkcí  $f$ , kde  $\int_{\Omega} f = 1$ ,  
 $P(A) := \int_A f$

V pravděpodobnostním prostoru  $(\Omega, \mathcal{F}, P)$  platí pro  $A, B \in \mathcal{F}$

1.  $P(A^c) = 1 - P(A)$  ... ( $A^c = \Omega \setminus A$ )
2.  $A \subseteq B \implies P(A) \leq P(B)$
3.  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$  ... PIE
4.  $P(A_1 \cup A_2 \cup \dots) \leq \sum_i P(A_i)$  (subaditivita, Booleova nerovnost)
5. Definujeme podmíněnou pravděpodobnost (pro  $P(B) > 0$ ).

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

6.  $Q(A) = P(A|B)$  splňuje axiomy pro pravděpodobnost.

$$P(\emptyset|B) = 0$$

$$P(\Omega|B) = \frac{P(B)}{P(B)} = 1$$

$$P(A_1 \circ A_2|B) = \frac{P((A_1 \circ A_2) \cup B)}{P(B)} = \frac{P((A_1 \cap B) \cup (A_2 \cap B))}{P(B)} = \frac{P(A_1 \cap B)}{P(B) + \frac{P(A_2 \cap B)}{P(B)}} = P(A_1|B) + P(A_2|B)$$

**Definice** (Zřetězené podmínování):

$$P(A \cup B) = P(B)P(A|B)$$

**Věta:** Pokud  $A_1, \dots, A_n \in \mathcal{F}$  a  $P(A_1 \cap \dots \cap A_n) > 0$ , tak

$$P(A_1 \cap A_2 \cap \dots \cap A_n) =$$

$$P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n | \bigcap_{i=1}^{n-1} A_i)$$

**Důkaz:** indukcí

□

**Příklad:** Příklad: vytáhneme 3 karty z balíčku 52 karet. Jaká je  $P(\text{žádné srdce})$ ?

$A_i$  = i-tá karta není srdce

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \times P(A_2|A_1)P(A_3|A_2 \cap A_1) = \frac{13 * 3}{52} \times \frac{13 * 3 - 1}{51} \times \frac{13 * 3 - 2}{50}$$

$$\frac{\# \text{dobrých}}{\# \text{všech}} = \frac{\binom{39}{3}}{\binom{52}{3}}$$

**Definice:** Spočetný systém množin  $B_1, B_2, \dots \in \mathcal{F}$  je rozklad (partition)  $\Omega$ , Pokud

1.  $B_i \cap B_j = \emptyset$  pro  $i \neq j$  a
2.  $\bigcup_i B_i = \Omega$ .

**Věta:** Věta o úplné pravdě. = Rozbor všech možností

Pokud  $B_1, B_2, \dots$  je rozklad  $\Omega$  a  $A \in \mathcal{F}$ , tak

$$P(A) = \sum_i P(B_i)P(A|B_i)$$

(sčítance s  $P(B_i) = 0$  považujeme za 0).

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots$$

(sjednocení disjunktních množin)

$$P(A) = \sum_i P(A \cap B_i) = \sum_i P(B_i)P(A|B_i)$$

**Příklad:** Máme tři mince: P+O, P+P, O+O. Jaká je pravděpodobnost, že padne orel?

Označíme  $M_1, M_2, M_3$  pro P+O, P+P, O+O.

$$\begin{aligned} P(O) &= P(M_1)P(O|M_1) + P(M_2)P(O|M_2) + P(M_3)P(O|M_3) \\ &= \frac{1}{3} \times \frac{1}{2} + \frac{1}{3} \times 0 + \frac{1}{3} \times 1 = \frac{1}{2} \end{aligned}$$

Rychlejší je vypsát si strom a pak počítat výsledné jevy

**Příklad** (Gambler's ruin - zbankrotování hazardního hráče.): Máme  $a$  korun, náš protivráč  $b$  korun. Hrajeme opakovaně spravedlivou hru o 1 Kč, dokud někdo nepřijde o všechny peníze. Jaká je pravděpodobnost, že vyhraje?

**Důkaz:**

$$\begin{aligned}
P_a &= P(\text{z této pozice vyhraje}) \\
P_0 &= 0, P_n = 1 \dots (a + b = n) \\
P(\text{výhra} | 1. \text{ kolo výhra}) &P(1. \text{ kolo výhra}) \\
+ P(\text{výhra} | 1. \text{ kolo prohra}) &P(1. \text{ kolo prohra}) \\
\text{výhra} &\implies P_{a+1}, \text{prohra} \implies P_{a-1} \\
P_a &= \frac{P_{a+1}}{2} + \frac{P_{a-1}}{2} \\
\text{ekvivalencia} &\iff \text{pls} \\
P_a - P_{a-1} &= P_{a+1} - P_a = \Delta \\
1 = P_n = P_0 + n * \Delta &\implies \Delta = \frac{1}{n} \\
P_a &= \frac{a}{a+b} = \frac{a}{n}
\end{aligned}$$

□

**Věta** (Bayesova Věta): Pokud  $B_1, B_2, \dots$  je rozklad  $\Omega$ ,  $A \in \mathcal{F}$ ,  $P(A) > 0$  a  $P(B_j) > 0$ , tak

$$P(B_j|A) = \frac{P(B_j)P(A|B_j)}{P(A)} = \frac{P(B_j)P(A|B_j)}{\sum_i P(B_i)P(A|B_i)}.$$

(sčítance s  $P(B_i) = 0$  považujeme za 0).**Důkaz:**

$$\begin{aligned}
P(B_j|A)P(A) &= P(B_j)P(A|B_j) \\
P(A \cap B_j) &= P(B_j \cap A)
\end{aligned}$$

□

**Příklad:**  $N$  = nemocný,  $T$  = testovaný, specif.  $P(N|T)$ , sens.  $P(T|N)$ .

$$P(N|T) = \frac{P(N)P(T|N)}{P(N)P(T|N) + P(N^c)P(T|N^c)} = \frac{p * 0.8}{p * 0.8 + (1 - p) * 0.01}$$

$$p = 0.001 \dots 7\%$$

$$p = 0.0016 \dots 56\% \dots \text{momentální stav testování}$$

$$p = 0.05 \dots 80\%$$

**Definice:** Jevy  $A, B \in \mathcal{F}$  jsou nezávislé (independenent) pokud  $P(A \cap B) = P(A)P(B)$ . Pak také platí  $P(A|B) = P(A)$ , pokud  $P(B) > 0$ .**Definice:** Jevy  $\{A_i : i \in I\}$  jsou (vzájemně) nezávislé, pokud pro každou konečnou množinu  $J \subseteq I$ 

$$P\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} P(A_i).$$

Pokud podmínka platí jen pro dvouprvkové množiny  $J$ , nazýváme jevy  $\{A_i\}$  po dvou nezávislé (pairwise independenent).



**Definice:** Necht' pro množiny z prostoru jevů platí

$$A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots$$

a  $A = \bigcup_{i=1}^{\infty} A_i$ . Pak platí

$$P(A) = \lim_{i \rightarrow \infty} P(A_i).$$

**Důkaz:**

$$A = A_1 \cup (A_2 \setminus A_1) \cup (A_3 \setminus A_2) \cup \dots$$

$$P(A) = P(A_1) + P(A_2 \setminus A_1) + P(A_3 \setminus A_2) + \dots$$

$$\lim_{i \rightarrow \infty} (P(A_1) + \dots + P(A_i \setminus A_{i-1})) = \lim_{i \rightarrow \infty} P(A_i).$$

□

$A_n \subset P, O^{\mathbb{N}}, A_n =$  mezi prvními  $n$  hody padl aspoň jednou orel.

$$P(A) = P(\geq 1 \text{ orel v } \infty \text{ hodech}) = \lim_{n \rightarrow \infty} \dots = 1$$

**Definice (Náhodná veličina):** Mějme pravděpodobnostní prostor  $(\Omega, \mathcal{F}, P)$ . Funkci  $X : \Omega \rightarrow \mathbb{R}$  nazveme diskrétní náhodná veličina, pokud  $I_m(X)$  je spočetná množina a pokud pro všechna reálna  $x$  platí

$$\{x \in \Omega : X(\omega) = x\} \in \mathcal{F}.$$

**Definice:** Pravděpodobnostní funkce diskrétní náhodné veličiny  $X$  je funkce  $p_X : \mathbb{R} \rightarrow [0, 1]$  taková, že

$$p_X(x) = P(X = x) = P(\{x \in \Omega : X(\omega) = x\})$$

**Definice:**  $\sum_{x \in I_m(X)} p_X(x) = 1$

**Definice:**  $S := I_m(X)1, Q(A) := \sum_{x \in A} p_X(x)$   
 $(S, \mathcal{P}(S), Q)$  je diskrétní pravděpodobnostní prostor.

**Definice:** Pro  $S = \{s_i : i \in I\}$  spočetnou množinu reálných čísel a  $c_i \in [0, 1]$   $\sum_{i \in I} c_i = 1$  existuje pravděpodobnostní prostor a diskrétní n.v.  $X$  na něm taková, že  $p_X(s_i) = c_i$  pro  $i \in I$ .

### 3 Třetí přednáška

**Definice (Distribuční funkce):** Distribuční funkce (cumulative distribution function, CDF) n.v.  $X$  je funkce

$$F_X(x) := P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\}).$$

1.  $F_X$  je neklesající funkce
2.  $\lim_{x \rightarrow -\infty} F_X(x) = 0$
3.  $\lim_{x \rightarrow +\infty} F_X(x) = 1$
4.  $F_X$  je zprava spojitá

**Příklad:**  $X = \{0 \text{ s pravděpodobností } \frac{1}{2}, 1 \text{ s pravděpodobností } \frac{1}{2}\}$

**Důkaz:**  $F_X$  je neklesající funkce

$$x < y \implies P(X \leq x) \leq P(X \leq y)$$

protože  $A = \{\omega : X(\omega) \leq x\}$ ,

$B = \{\omega : X(\omega) \leq y\}$ , pak

$$A \subseteq B \implies P(A) \leq P(B)$$

□

**Důkaz:**  $\lim_{x \rightarrow +\infty} F_X(x) = 1$

$$A_n = X \leq n; \text{ platí } A_1 \subseteq A_2 \subseteq \dots$$

Takže  $\bigcup_{n=1}^{\infty} A_n = \Omega$ , podle věty o spojitosti pak

$$P(\Omega) = \lim_{n \rightarrow \infty} P(A_n) = \lim_{n \rightarrow \infty} F_X(n)$$

□

druhá limita obdobně

**Definice** (Bernoulliho/alternativní rozdělení): white x

1.  $X$  = počet orlů při jednom hodu nespravedlivou mincí.

2. Značíme  $X \sim \text{Bern}(p)$ . Někdy se značí  $\text{Alt}(p)$ .

1. Dáno  $p \in [0, 1]$ .

2.  $p_X(1) = p$

3.  $p_X(0) = 1 - p$

4.  $p_X(k) = 0$  pro  $k \neq 0, 1$

1. Pro libovolný jev  $A \in \mathcal{F}$  definujeme *indikátorovou* n.v.  $I_A$ :

2.  $I_A(\omega) = 1$  pokud  $\omega \in A$ ,  $I_A(\omega) = 0$  jinak.

3.  $I_A \sim \text{Bern}(P(A))$ .

**Definice:** white x

1.  $X$  = počet orlů při  $n$  hodech nespravedlivou mincí.

2. Dáno  $p \in [0, 1]$  – pravděpodobnost orla při jednom hodu.

3. Značíme  $X \sim \text{Bin}(n, p)$ .

1.  $X = \sum_{i=1}^n X_i$  pro nezávislé n.v.  $X_1, \dots, X_n \sim \text{Bern}(p)$ .

2.  $p_X(k) = P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$  pro  $k \in 0, 1, \dots, n$ .

$$\sum_{k=1}^n \binom{n}{k} p^k (1-p)^{n-k} = 1$$

$$(p + (1-p))^n = 1^n = 1$$

**Definice** (Hypergeometrické rozdělení): white x

1.  $X$  = počet vytažených červených míčku při  $n$  tazích, v osudí je  $K$  červených z  $N$  celkových míčků

2. Dáno  $n, N, K$ .

3. Značíme  $X \sim \text{Hyper}(N, K, n)$ .

4.  $p_X(k) = P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$

**Definice** (Poissonovo rozdělení (poasón)): white x

1. Značíme  $X \sim Pois(\lambda)$ .
2. Dáno reálné  $\lambda > 0$ .
3.  $p_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}$
4.  $Pois(\lambda)$  je limitou  $Bin(n, \lambda/n) \dots \sim X_n \dots \lambda$  pevné
5.  $X$  popisuje např. počet emailů, které dostaneme za jednu hodinu.

chceme  $\sum \frac{\lambda^k}{k!} e^{-\lambda} = 1$

$$\begin{aligned} e^\lambda &= \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \\ P(X_n = k) &= \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} = \\ &= \frac{n(n-1)\dots(n-k+1)}{k!} \frac{\lambda^k}{n^k} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} = \\ &= \frac{\lambda^k}{k!} e^{-\lambda} \end{aligned}$$

**Poznámka** (Poissonovo paradigma):  $A_1, \dots, A_n$  jsou (skoro-)nezávislé jevy s  $P(A_i) = p_i$ ,  $\lambda = \sum_j p_j$ .  
Nechť  $n$  je velké, každé  $p_i$  malé. Pak přibližně platí

$$\sum_{i=1}^n I_{A_i} \sim Pois(\lambda)$$

**Definice** (Geometrické rozdělení): white x

1.  $X$  = kolikátým hodem mincí padl první orel.
2. Značíme  $X \sim Geom(p)$ .
3. Dáno  $p \in [0, 1]$ .
4.  $p_X(k) = (1-p)^{k-1}p$ , pro  $k = 1, 2, \dots$
5. Někdy se tomuto rozdělení říká posunuté geometrické, a za normální geometrické se považuje rozdělení  $X - 1$ , t.j. počet neúspěšných hodů.

**Důkaz:** chceme  $\sum (1-p)^{k-1}p = 1$

$$= \frac{(1-p)^0 p}{1 - (1-p)} = \frac{p}{p} = 1$$

□

**Definice** (Střední hodnota): Pokud  $X$  je diskrétní n.v., tak její střední hodnota (expectation) je označovaná  $\mathbb{E}(X)$  a definovaná

$$\mathbb{E}(X) = \sum_{x \in Im(X)} x \times P(X = x),$$

pokud součet má smysl.

Nechť  $X$  je definovaná na diskrétním prostoru  $(\Omega, \mathcal{F}, P)$ . Pak střední hodnotu lze také definovat

$$\mathbb{E}(X) = \sum_{\omega \in \Omega} X(\omega)P(\omega).$$

... vážený průměr **Důkaz:** dk., že obě definice souhlasí.

$$\sum_{x \in \text{Im}(X)} \sum_{\omega \in \Omega} X(\omega)P(\omega) = \sum_{x \in \text{Im}(X)} (x \times P(\omega \in \Omega : X(\omega) = x))$$

□

**Definice (Rozptyl):** Rozptyl(variace) n.v.  $X$  nazveme číslo  $\mathbb{E}((X - \mathbb{E}X)^2)$ .  
Značíme jej  $\text{var}(X)$

**Věta:**

$$\text{var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

**Definice (LOTUS (Law of The Unconscious Statisticist)):** Pro reálnou funkci  $g$  a diskrtétní n.v.  $X$  je  $Y = g(X)$  také diskrétní n.v.

**Věta (LOTUS):** Pokud  $X$  je diskrétní n.v. a  $g$  reálná funkce, tak

$$\mathbb{E}(g(X)) = \sum_{x \in \text{Im}(X)} g(x)P(X = x)$$

pokud součet má smysl.

**Důkaz:**

$$Y = g(X)$$

$$\begin{aligned} \mathbb{E}Y &= \sum_{y \in Y} y \times P(Y = y) \dots \text{definice} \\ &= \sum_{y \in Y} \sum_{x \in \text{Im}(X)} g(x)P(X = x) \\ &= \sum_{x \in \text{Im}(X)} g(x)P(X = x) \end{aligned}$$

□

## 4 Čtvrtá přednáška

**Věta:** *Věta*

Nechť  $X, Y$  jsou diskrétní n.v. a  $a, b \in \mathbb{R}$ .

1. Pokud  $P(X \geq 0) = 1$  a  $\mathbb{E}(X) = 0$ , tak  $P(X = 0) = 1$ .
2. Pokud  $\mathbb{E}(X) \geq 0$  tak  $P(X \geq 0) > 0$ .
3.  $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$ .
4.  $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$

**Důkaz: 1.**

$$\begin{aligned}\mathbb{E}(X) &= \sum_{x \in X} xP(X=x) = 0P(X=0) + \sum_{x>0 \& x \in X} xP(X=x) = \sum_{x>0 \& x \in X} xP(X=x) = 0 \\ &\implies \forall x > 0 : P(X=x) = 0 \implies P(X=0) = 1\end{aligned}$$

2.

$$\mathbb{E}(X) = \sum xP(X \geq x) = 0$$

kdyby ne:  $P(X \geq 0) = 0$ , všechny členy v sumě by byly záporné...spor

3.

$$\mathbb{E}(aX + b) = \sum_{x \in X} (ax + b)P(X=x) = a \sum xP(X=x) + b \sum P(X=x)$$

4.

$$\mathbb{E}(X + Y) = \sum_{\omega} (X(\omega) + Y(\omega))P(\omega) = \sum X(\omega)P(\omega) + \sum Y(\omega)P(\omega) = \mathbb{E}(X) + \mathbb{E}(Y)$$

□

**Věta:** Necht  $X$  je diskrétní n.v. nabývající jen hodnot z  $\mathbb{N} = 0, 1, 2, \dots$ . Pak platí

$$\mathbb{E}(X) = \sum_{n=0}^{\infty} P(X > n).$$

**Důkaz:**

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=0}^{\infty} kP(X=k) = \sum_{k=0}^{\infty} \sum_{n=0}^{k-1} P(X=k) \\ &= \sum_{n=0}^{\infty} \sum_{k=n+1}^{\infty} P(X=k) = \sum_{n=0}^{\infty} \sum_{k=n+1}^{\infty} P(\omega \in \Omega : X(\omega) = k) \\ &= \sum_{n=0}^{\infty} P(\omega \in \Omega : X(\omega) > n) = \sum_{n=0}^{\infty} P(X > n)\end{aligned}$$

□

**Definice:** Rozptyl

Rozptyl (*variance*) n.v.  $X$  nazveme číslo  $\mathbb{E}((X - \mathbb{E}(X))^2)$ .

Značíme jej  $\text{var}(X)$ . ... (kvadratické měření odchylky)

1. Směrodatná odchylka (standard deviation)  $\sigma_X = \sqrt{\text{var}(X)}$

**Poznámka:** "stejně jednotky jako  $X$ "

2. Měří, jak je daleko "typicky"  $X$  od  $\mathbb{E}(X)$ . Mohli bychom to měřit i jinak (např.  $\mathbb{E}(|X - \mathbb{E}(X)|)$ ), ale rozptyl je výhodnější.

**Věta:** *Věta*

$$\text{var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

**Důkaz:**

$$\begin{aligned}\mu &= \mathbb{E}(X) \\ \text{var}(X) &= \mathbb{E}((X - \mu)^2) = \mathbb{E}(X^2 - 2\mu X + \mu^2) = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 \\ &= \end{aligned}$$

□

**Definice:** Podmíněná střední hodnota

Pokud  $X$  je diskrétní n.v. a  $P(B) > 0$ , tak podmíněná střední hodnota  $X$  za předpokladu  $B$  (conditional expectation of  $X$  given by  $B$ )

**Věta:** *Věta o úplné střed. hodnotě*

*Pokud  $B_1, B_2, \dots$  je rozklad  $\Omega$  a  $X$  je d.n.v., tak*

$$\mathbb{E}(X) = \sum_i \mathbb{E}(X|B_i)P(B_i)$$

*kdykoliv má součet smysl. (Sčítance s  $P(B_i) = 0$  považujeme za 0.)* **Důkaz:**

$$\begin{aligned}\mathbb{E}(X) &= \sum_i P(B_i)\mathbb{E}(X|B_i) \\ &= \sum_i P(B_i) \sum_x xP(X=x|B_i) \\ &= \sum_x x \left( \sum_i P(B_i)P(X=x|B_i) \right)\end{aligned}$$

□

*Rozbor všech možností  $X \sim \text{Geom}(p)$*

$B_1 = S \dots$  první pokus úspěšný

$B_2 = B_1^C = F \dots$  první pokus neúspěšný

$$\begin{aligned}\mathbb{E}(X) &= P(S)\mathbb{E}(X|S) + P(F)\mathbb{E}(X|F) \\ &= p \cdot 1 + (1-p)(\mathbb{E}(X+1)) \\ p\mathbb{E}(X) &= p + (1-p) = 1 \\ \mathbb{E}(X) &= \frac{1}{p}\end{aligned}$$

**Věta:** *Parametry rozdělení - Bernoulliho*

*Pro  $X \sim \text{Bern}(p)$  je*

$$1. \mathbb{E}(X) = p$$

$$2. \text{var}(X) = p(1-p)$$

**Důkaz:**  $\mathbb{E}(X) = 0P(X=0) + 1P(X=1) = P(X=1) = p$

$$\text{var}(X) = \mathbb{E}(X-p)^2 = (0-p)^2P(X=0) + (1-p)^2P(X=1) = p(1-p)(p + (1-p)) = p(1-p) \quad \square$$

**Věta:** Parametry rozdělení - binomické

Pro  $X \sim \text{Bin}(n, p)$  je

1.  $\mathbb{E}(X) = np$

2.  $\text{var}(X) = np(1 - p)$

1. První postup:  $X = \sum_{i=1}^n X_i$ , kde  $X_i = [i\text{-tý hod uspěl}]$

$$\mathbb{E}(X_i) = P(X_i = 1) = p$$

2. Druhý postup:

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=0}^n kP(X = k) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^n pn \binom{n-1}{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)} \\ &= pn(p + (1-p))^{n-1} = np\end{aligned}$$

**Věta:** Parametry rozdělení - hypergeometrické

Pro  $X \sim \text{Hyper}(N, K, n)$  je

1.  $\mathbb{E}(X) = n \frac{K}{N}$

2.  $\text{var}(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}$

1. První postup:  $X = \sum_{i=1}^n X_i$ , kde  $X_i = [i\text{-tý míček červený}]$

$$\mathbb{E}(X_i) = P(X_i = 1) = \frac{K}{N}$$

2. Druhý postup:

$$\mathbb{E}(X) = \sum_{j=1}^K Y_j, \text{ kde } Y_j = [byl \text{ vytažen (z } n \text{ tahů) míček s číslem } j]$$

$$\begin{aligned}\mathbb{E}(Y_j) &= P(Y_j = 1) = \frac{n}{N} \\ &= \frac{\binom{N-1}{n-1}}{\binom{N}{n}} = \frac{n}{N}\end{aligned}$$

**SKONTROLOVATĚ, STRATIL SOM SA :Sadge:**

**Věta:** Parametry rozdělení - geometrické

Pro  $X \sim \text{Geom}(p)$  je

1.  $\mathbb{E}(X) = \frac{1}{p}$

2.  $\text{var}(X) = \frac{1-p}{p^2}$

**Věta:** Parametry rozdělení - hypergeometrické

Pro  $X \sim \text{Hyper}(N, K, n)$  je

1.  $\mathbb{E}(X) = \lambda$
2.  $\text{var}(X) = \lambda$

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

$$\mathbb{E}(X) = \sum k \frac{\lambda^k}{k!} e^{-\lambda} = 1$$

$$\lambda \sum \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} = \lambda$$

**Definice:** Základní popis náhodných vektorů

1.  $X, Y$  - nestihol som, lebo preskočil slide za 2 sekundy :) boli tam asi 4 odrážky

**Definice:** Nejaká definícia, nesithol som, lebo som rantoval

**Definice:** Marginální rozdělení

1. Máme-li dáno  $p_{X,Y}$ , jak zjistit rozdělení jednotlivých složek, t.j.  $p_X$  a  $p_Y$  ?

**Důkaz:** Necht'  $X, Y$  jsou diskrétní n.v. Pak:

$$p_X(x) = P(X = x) = \sum_{Y \in \text{Im}(Y)} P(X = x \& Y = y) = \sum_{Y \in \text{Im}(Y)} p_{X,Y}(x, y)$$

$$p_Y(y) = P(Y = y) = \sum_{X \in \text{Im}(X)} P(X = x \& Y = y) = \sum_{Y \in \text{Im}(Y)} p_{X,Y}(x, y)$$

□

**Definice:** Nezávislost náhodných veličin

Diskrétní n.v.  $X, Y$  jsou nezávislé (independent) pokud pro každé  $x, y \in \mathbb{R}$  jsou jevy  $\{X = x\}$  a  $\{Y = y\}$  nezávislé. To nastane právě když

$$P(X = x, Y = y) = P(X = x)P(Y = y).$$

**Věta:** Součin nezávislých n.v.

Pro nezávislé diskrétní n.v.  $X, Y$  platí

$$\mathbb{E}XY = \mathbb{E}(X)\mathbb{E}(Y)$$

**Důkaz:**

$$\begin{aligned} \mathbb{E}(XY) &= \sum_{x \in \text{Im}(X), y \in \text{Im}(Y)} P(X = x, Y = y) \\ &= \sum_x x P(X = x) \sum_y y P(Y = y) = \mathbb{E}(X)\mathbb{E}(Y) \end{aligned}$$

□



## 5 Pátá přednáška

**Definice:** Coupling

1.  $X = \sum_{i=1}^n X_i$  kde  $X_1, \dots, X_n$  jsou n.n.v.  $\dots \sim \text{Bern}(p)$
2.  $Y = \sum_{i=1}^n Y_i$  kde  $Y_1, \dots, Y_n$  jsou n.n.v.  $\dots \sim \text{Bern}(q) \dots o < q$
3. vztah  $X, Y$  není určen, můžou být jakékoliv.
4. Zařídíme, že nebudou nezávislé, dokonce bude vždy  $X \leq Y$ .
5. Stačí definovat:

$$\text{pokud } X_i = 1 \text{ tak } Y_i = 1$$

$$\text{pokud } X_i = 0 \text{ tak } Y_i \text{ buď } 1 \text{ nebo } 0$$

$$\implies Y_1, \dots, Y_n \text{ jsou n.n.v. } \implies Y \sim \text{Bin}(n, q)$$

$$\implies X \leq Y \text{ vždy } (Y \leq k \implies X \leq k) \implies P(X \leq k) \geq P(Y \leq k)$$

**Věta:** Funkce náhodného vektoru

Nechť  $X, Y$  jsou n.v. na  $(\Omega, \mathbb{F}, P)$ , nechť  $g: \mathbb{R}^2 \rightarrow \mathbb{R}$  je funkce.

1. Pak  $Z = g(X, Y)$  je n.v. na  $(\Omega, \mathbb{F}, P)$

2. platí pro ni

$$\mathbb{E}(g(X, Y)) = \sum_{x \in \text{Im}(X)} \sum_{y \in \text{Im}(Y)} g(x, y) P(X = x, Y = y)$$

Věta (linearita střední hodnoty)

Pro  $X, Y$  n.v. a  $a, b \in \mathbb{R}$  platí

$$\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y)$$

The End